SISTEMAS PARALELOS

Clase 4 – Análisis de rendimiento

Prof Dr Enzo Rucci

FACULTAD DE INFORMATICA
UNIVERSIDAD NACIONAL DE LA PLATA

Agenda de esta clase

- Análisis de rendimiento

ANÁLISIS DE RENDIMIENTO EN SISTEMAS PARALELOS

Rendimiento (o prestaciones)

Cantidad de transacciones (efectivas) en un espacio de tiempo

- Término *amplio*

Avión	Washington a París (hs)	Velocidad (mph)	Pasajeros (p)	Throughput (pmph)
747	6.5	610	470	286700
Concorde	3h	1350	132	178200

- ¿Cuál de los presenta mejor rendimiento?
  - Depende de la **métrica** que usemos para evaluar
    - Tiempo para completar la tarea (tiempo de ejecución, latencia, tiempo de respuesta, u otras derivadas).
    - Tareas completadas por unidad de tiempo (throughput, ancho de banda)
  - Tiempo de respuesta y throughput a veces conflictúan entre sí
  - Los sistemas paralelos suelen ser sistemas dedicados, que priorizan las métricas basadas en tiempo.

Métricas - Tiempo de ejecución

- Un algoritmo secuencial se suele evaluar por su tiempo de ejecución → En general, es posible encontrar alguna ley asintótica del tiempo de ejecución en función del tamaño de datos de entrada
- El tiempo de ejecución de un programa paralelo no sólo depende del tamaño de los datos de entrada sino también del número de procesadores y de los parámetros de comunicación de la arquitectura de soporte → es incorrecto analizar el algoritmo paralelo en forma aislada

*El análisis se debe realizar a nivel de **sistema paralelo** (combinación de algoritmo paralelo y contexto de hardware y software).*

Métricas - Tiempo de ejecución

- El ***tiempo de ejecución secuencial (T_s)*** es el tiempo que transcurre desde el inicio hasta el fin de la ejecución sobre una máquina empleando una única unidad de procesamiento.

- El ***tiempo de ejecución paralela (T_p)*** resume la diferencia de tiempo entre que la primera tarea que comienza hasta que la última tarea haya completado su trabajo.

Fuentes de overhead

- Usando el doble de recursos, se espera que el programa paralelo se ejecute en la mitad del tiempo → Sin embargo, en la práctica, esto es muy raro que ocurra.

- Existen factores que generan overhead en los programas paralelos e impiden una mejora proporcional al aumento de la arquitectura:
  - Ocio
  - Interacción entre procesos
  - Cómputo adicional

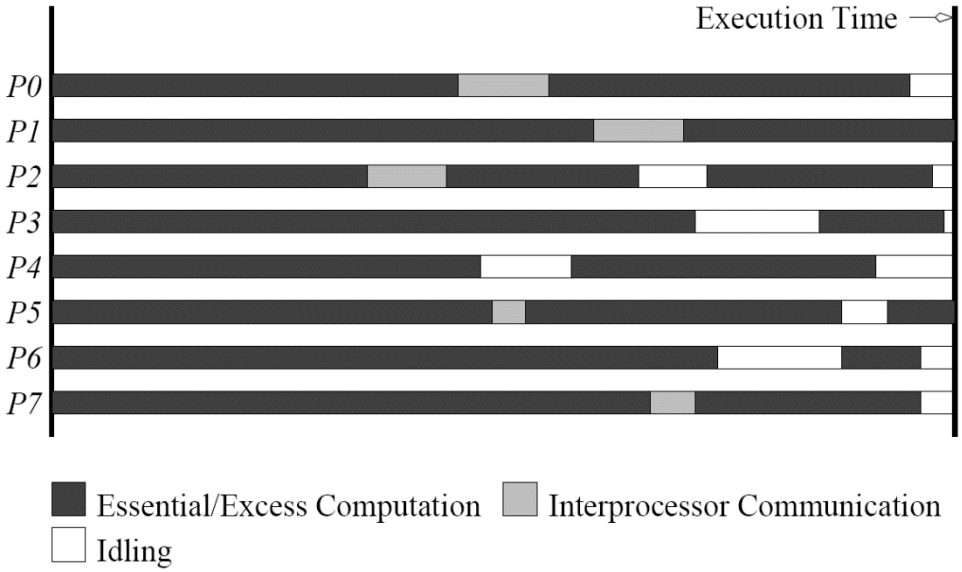

Métricas – Speedup

- El ***Speedup (S)*** refleja el beneficio de emplear procesamiento paralelo para resolver un problema dado comparado a realizarlo en forma secuencial

$$S_p(n) = \frac{T_s(n)}{T_p(n)}$$

- Es una medida de cuántas veces más rápido pudimos resolver el problema empleando el algoritmo paralelo con *p* unidades de procesamiento comparado al algoritmo secuencial.
- Para un problema dado, pueden existir diferentes algoritmos secuenciales, los cuales pueden tener diferentes tiempo de ejecución (complejidad) y, a su vez, pueden ser paralelizados de distintas maneras.
- Para computar el Speedup, siempre se debe considerar **el mejor algoritmo secuencial** (el que resuelva el problema en menos tiempo).

Métricas – Speedup

- Límites del Speedup:
  - Si $S_p(n) < 1$ entonces el algoritmo paralelo tarda más que el mejor algoritmo secuencial → $S_p(n)$ debe ser mayor a 1
  - El mejor resultado se logra si somos capaces de distribuir el trabajo entre las unidades de procesamiento sin introducir ocio, interacción ni cómputo adicional → Situación poco usual
    - Con *p* unidades de procesamiento → $S_p(n) = p$ (conocido como *Speedup lineal*, *Speedup óptimo, Speedup perfecto)*
  - Teóricamente, siempre se cumple que $S_p(n) \leq p$
    - Un Speedup mayor a *p* sólo es posible si cada unidad de procesamiento requiere menos de $\frac{T_S(n)}{p}$ unidades de tiempo
    - Entonces podríamos construir un nuevo algoritmo secuencial que emule las *p* unidades de procesamiento usando una única unidad física, resolviendo el problema en menos de *Ts* unidades de tiempo → **Contradicción**

Métricas – Speedup

- En la práctica, a veces se puede dar $S_p(n) > p$ (fenómeno conocido como *Speedup superlineal*)
  - Un motivo puede ser que la versión paralela del algoritmo realice *menos* trabajo que la versión secuencial
  - Ejemplo: búsqueda *Depth-First-Search* en árbol binario, donde expandir cada nodo cuesta t_c

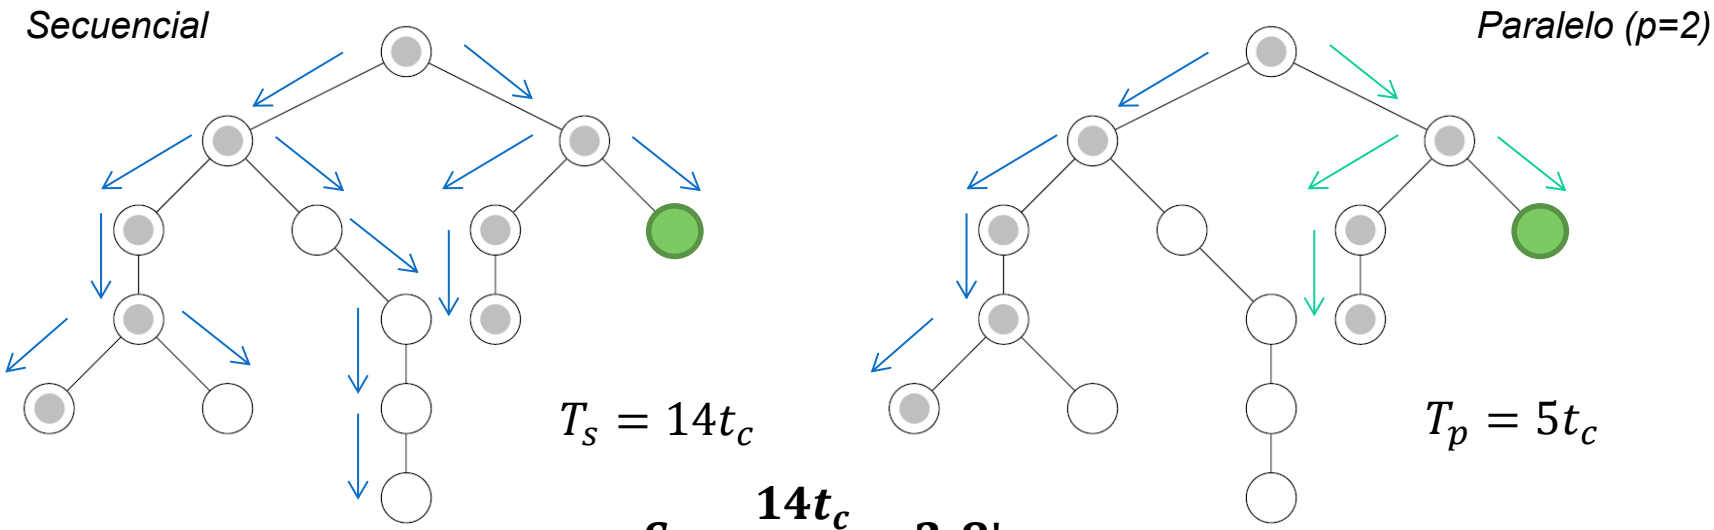

$T_s = 14t_c$

$T_p = 5t_c$

$$\boldsymbol{S_p = \frac{14t_c}{5t_c} = 2.8!}$$

Métricas – Speedup

- Un segundo motivo de Speedup superlineal es la combinación de características de hardware y distribución de los datos del algoritmo paralelo que ponen en desventaja al algoritmo secuencial

- Por ejemplo, consideremos un procesador con 64Kb de caché y un algoritmo secuencial con 80% de hits en la caché:
  - Si el algoritmo paralelo emplea 2 procesadores, disminuye el volumen de datos con los que se trabaja, llevando la tasa de hits al 90%
  - Siguiendo este razonamiento, al emplear 4 procesadores, se podría alcanza una tasa de 100% de hits.

Métricas – Speedup

- Calculemos las relaciones para 20.000 accesos a memoria considerado que:
  - la latencia de la caché es 2 ns;
  - el tiempo de acceso a memoria es 100 ns;
  - el tiempo de acceso a disco es 1000 ns;
  - los fallos de caché se reparten 80% en RAM y 20% en disco.

Secuencial → 16.000 × 2 ns + 3.200 × 100 ns + 800 × 1000 ns = 1152 ms

Paralelo (*p*=2) → 18.000 × 2 ns + 1.600 × 100 ns + 400 × 1000 ns = 0,596 ms

Paralelo (*p*=4) → 20.000 × 2 ns = 0,04 ms → $S_p = \frac{1152}{0{,}4} = 2880$

¿Es una causa real de speedup superlineal?

Métricas – Speedup

- Lo visto hasta ahora asume que todas las unidades de procesamiento empleadas son idénticas
- En arquitecturas heterogéneas, el Speedup se debe calcular considerado la Potencia Cómputo Total (*pct*) en lugar del número de unidades de procesamiento (*p*)

$$pct = \sum_{i=0}^{p-1} pcr_i$$

$$pcr_i = \frac{p_i}{p_m}$$

pct	Potencia de Cómputo Total
pcr	Potencia de Cómputo Relativa
p_i	Potencia del procesador *i*
p_m	Potencia del mejor procesador

Métricas – Speedup

- Consideremos una arquitectura compuesta por 8 procesadores ($p_0..p_7$), donde p_0 es el de mayor potencia, p_1.. p_4 tienen un 75% de la potencia de p_0 y p_5.. p_7 tienen el 50% de potencia de p_0; entonces:

$$pcr_0 = 1$$
$$pcr_{1..4} = 0{,}75$$
$$pcr_{5..7} = 0{,}5$$

$$pct = \sum_{i=0}^{7} pcr_i = 1 + 4 \times 0{,}75 + 3 \times 0{,}5 = 5{,}5$$

- El límite superior para el Speedup en esta arquitectura es 5,5 más allá de contar con 8 procesadores

¿Cómo calcular potencia de cada unidad de procesamiento?

Métricas – Eficiencia

- Sólo un sistema paralelo ideal con *p* unidades de procesamiento puede reportar speedups iguales a *p* → En la práctica es difícil que ocurra debido a las fuentes de overhead
- La **Eficiencia** es una medida de la fracción de tiempo en la cual las unidades de procesamiento son empleadas en forma útil

$$E_p(n) = \frac{S_p(n)}{S_{Opt}}$$

- En arquitecturas homogéneas $S_{Opt} = p$ mientras que en heterogéneas $S_{Opt} = pct$
- Si $S_p(n) = p$ (sistema paralelo ideal), entonces $E_p(n) = 1$
- En la práctica, $S_p(n) \leq p$ lo que implica que $E_p(n) \leq 1$
- Por definición, $E_p(n) > 0$. Por lo tanto, $0 < E_p(n) \leq 1$

Métricas – Overhead de las comunicaciones

- El ***overhead de las comunicaciones*** de un sistema paralelo se define como la relación entre el tiempo requerido por las comunicaciones de nuestra solución y el tiempo total que esta requiera.

$$OC_p(n) = \frac{Tcomm_p(n)}{T_p(n)} \times 100$$

Métricas – Ejemplos de Speedup, Eficiencia y Overhead

Tiempos de ejecución y valores de Speedup y Eficiencia para algoritmos que resuelven multiplicación de matriz-vector

$T_s(n)$

$T_P(n)$

p	Order of Matrix				
	1024	*2048*	*4096*	*8192*	*16,384*
1	4.1	16.0	64.0	270	1100
2	2.3	8.5	33.0	140	560
4	2.0	5.1	18.0	70	280
8	1.7	3.3	9.8	36	140
16	1.7	2.6	5.9	19	71

$S_p\ (n)$

p	Order of Matrix				
	1024	*2048*	*4096*	*8192*	*16,384*
1	-	-	-	-	-
2	1.8	1.9	1.9	1.9	2.0
4	2.1	3.1	3.6	3.9	3.9
8	2.4	4.8	6.5	7.5	7.9
16	2.4	6.2	10.8	14.2	15.5

$E_p\ (n)$

p	Order of Matrix				
	1024	*2048*	*4096*	*8192*	*16,384*
1	-	-	-	-	-
2	0.89	0.94	0.97	0.96	0.98
4	0.51	0.78	0.89	0.96	0.98
8	0.30	0.61	0.82	0.94	0.98
16	0.15	0.39	0.68	0.89	0.97

T_s, T_p, S y E dependen del tamaño de problema

T_p, S y E además dependen de p

Métricas – Ejemplos de Speedup, Eficiencia y Overhead

Gráficos de Speedup y Eficiencia para las tablas anteriores

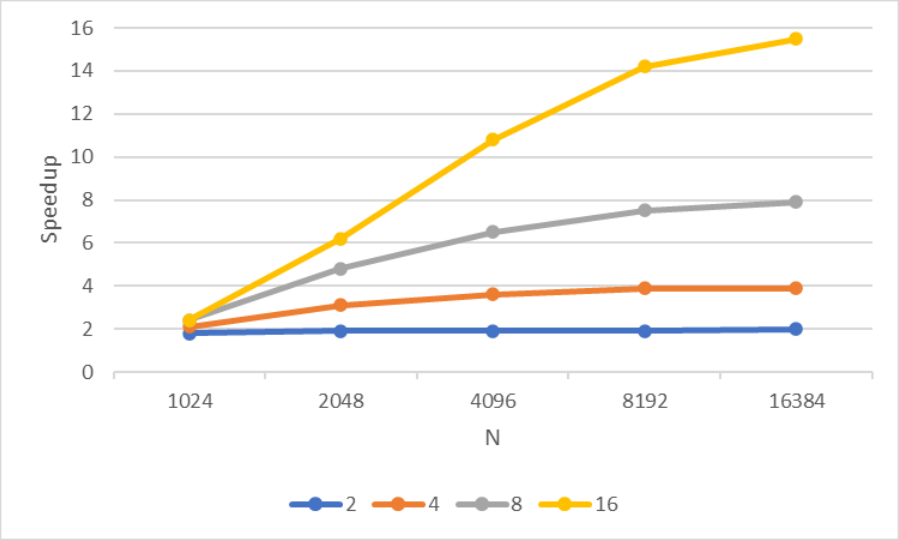

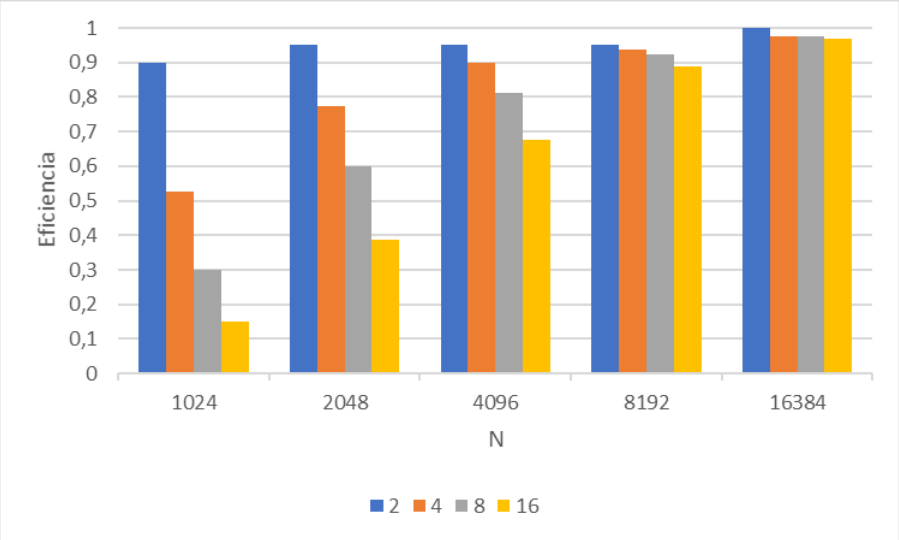

Métricas – Ejemplos de Speedup, Eficiencia y Overhead

Gráfico de Overhead (com) y Eficiencia para las tablas anteriores

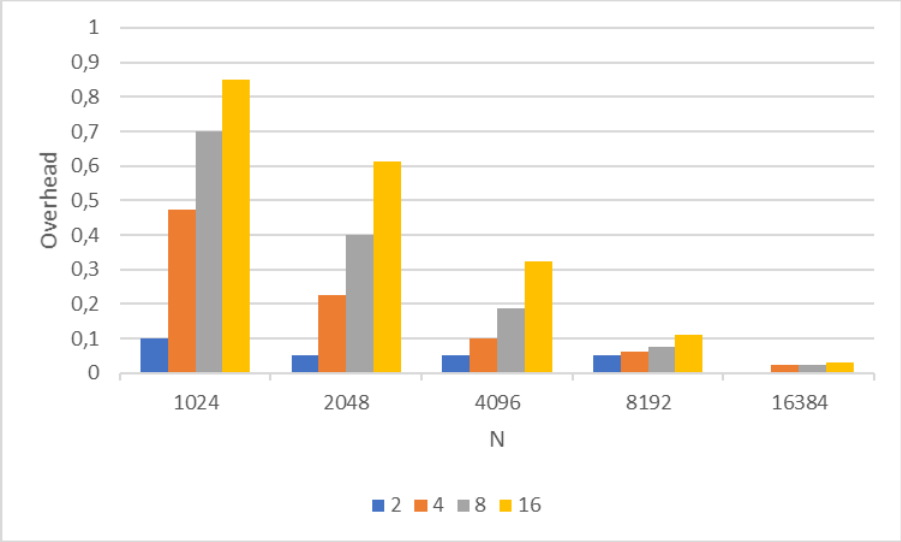

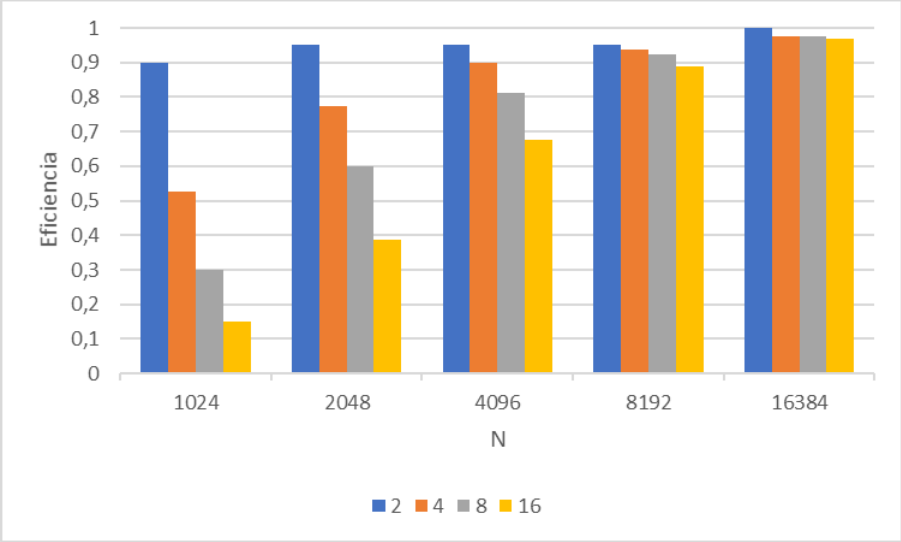

Métricas – Ley de Amdahl

- Los factores de overhead limitan los beneficios del procesamiento paralelo
- Una restricción importante proviene de aquellos secciones de código que no pueden ser paralelizadas → bloque de ejecución secuencial
- La **Ley de Amdahl** (Amdahl, 1967) permite estimar el Speedup alcanzable en aquellos programas paralelos que contienen partes secuenciales:
- Dada una fracción *f*, $0 \leq f \leq 1$, de un programa paralelo que debe ser ejecutada secuencialmente, el tiempo de ejecución paralela se calcula como:

$$T_p(n) = f \times T_s(n) + \frac{(1-f) \times T_s(n)}{p}$$

- Entonces el Speedup ahora puede re-escribirse de la siguiente forma:

$$S^A{}_P\,(n) = \frac{T_s(n)}{f \times T_s(n) + \frac{(1-f) \times T_s(n)}{p}} = \frac{1}{f + \frac{(1-f)}{p}}$$

Métricas – Ley de Amdahl

- Es importante notar que, aun con un número infinito de unidades de procesamiento, el Speedup estará limitado a $\frac{1}{f}$, ya que:

$$\lim_{p \to \infty} \left(\frac{1}{f + \frac{(1-f)}{p}} \right) = \frac{1}{f}$$

- Por ejemplo, con 5% de ejecución secuencial ($f = 0.05$) en un programa paralelo, el máximo Speedup alcanzable será **20**, sin importar el número de unidades de procesamiento que podamos emplear.

- Es importante tener en cuenta esta características si vamos a emplear una gran cantidad de unidades de procesamiento, aunque veremos más adelante que esta estimación puede ser considerada *poco realista.*

Métricas – Escalabilidad

- En el contexto de análisis de rendimiento, la escalabilidad hace referencia a la capacidad que tiene un sistema de mantener un nivel de Eficiencia fijo al incrementar tanto el número de unidades de procesamiento como el tamaño del problema de resolver → En ese caso, se dice que el sistema es ***escalable***

- Dicho de otra manera, la escalabilidad de un sistema paralelo es una medida de su capacidad de incrementar el Speedup en forma proporcional al número de unidades de procesamiento empleadas

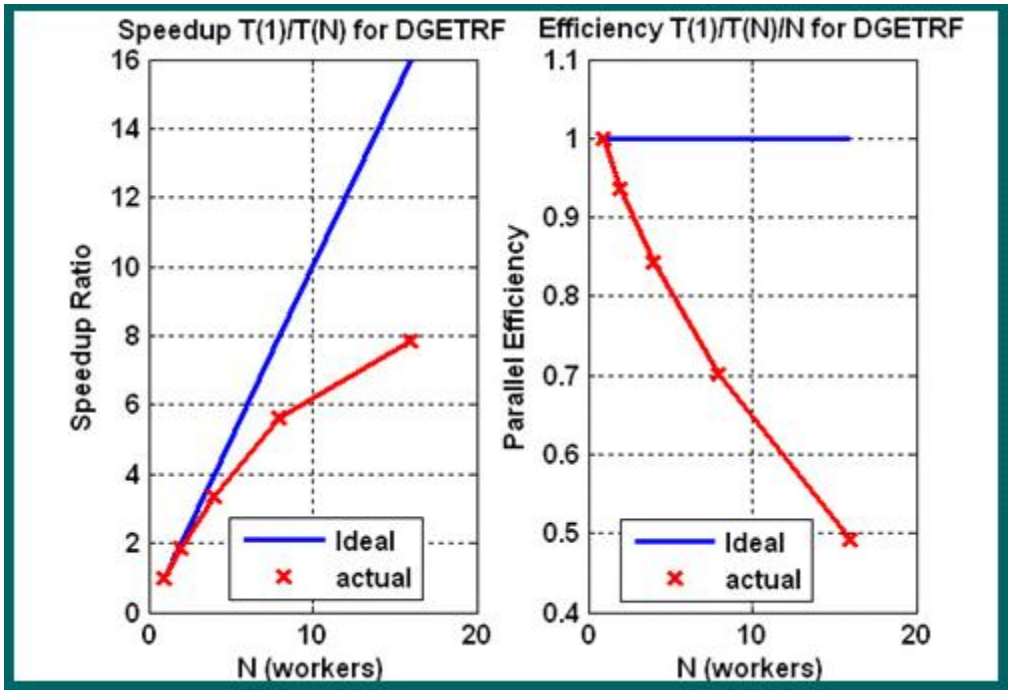

Métricas – Escalabilidad

- Casos especiales:
  - *Escalabilidad fuerte*: Cuando al incrementar el número de unidades de procesamiento, no resulta necesario aumentar el tamaño de problema para mantener la eficiencia en un valor fijo.

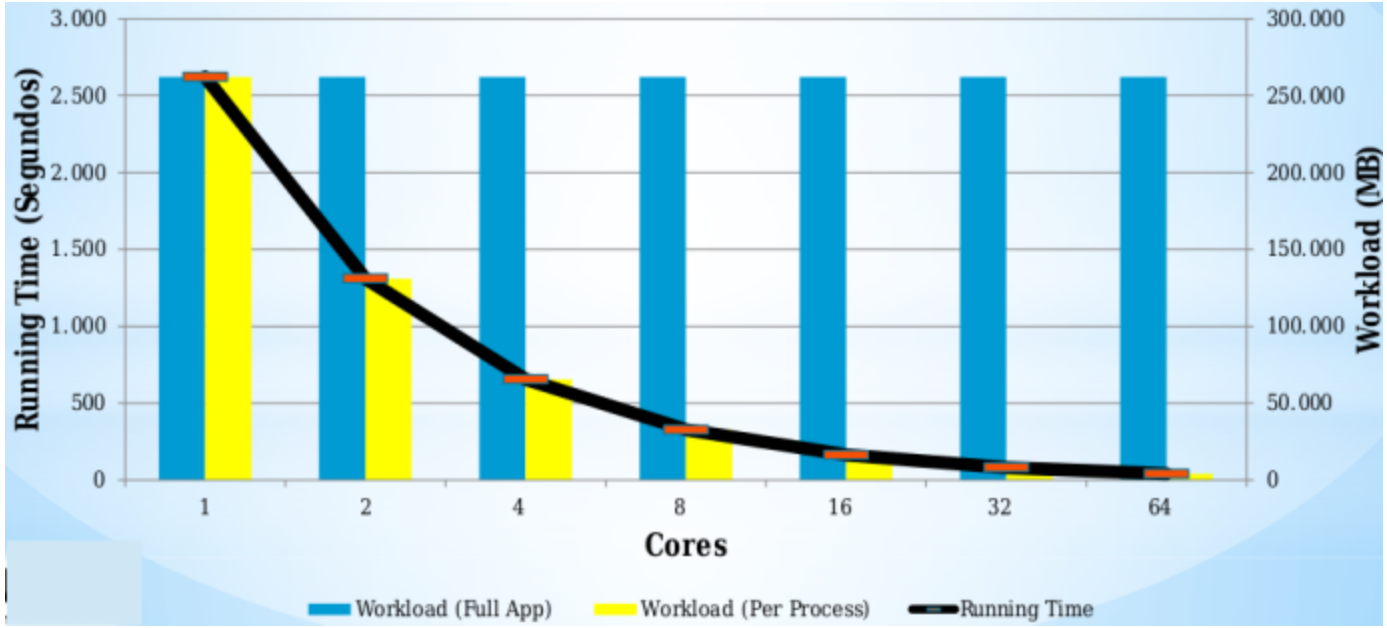

Métricas – Escalabilidad

- Casos especiales:
  - *Escalabilidad débil*: Cuando al incrementar el número de unidades de procesamiento, resulta necesario también aumentar el tamaño de problema para mantener la eficiencia en un valor fijo.

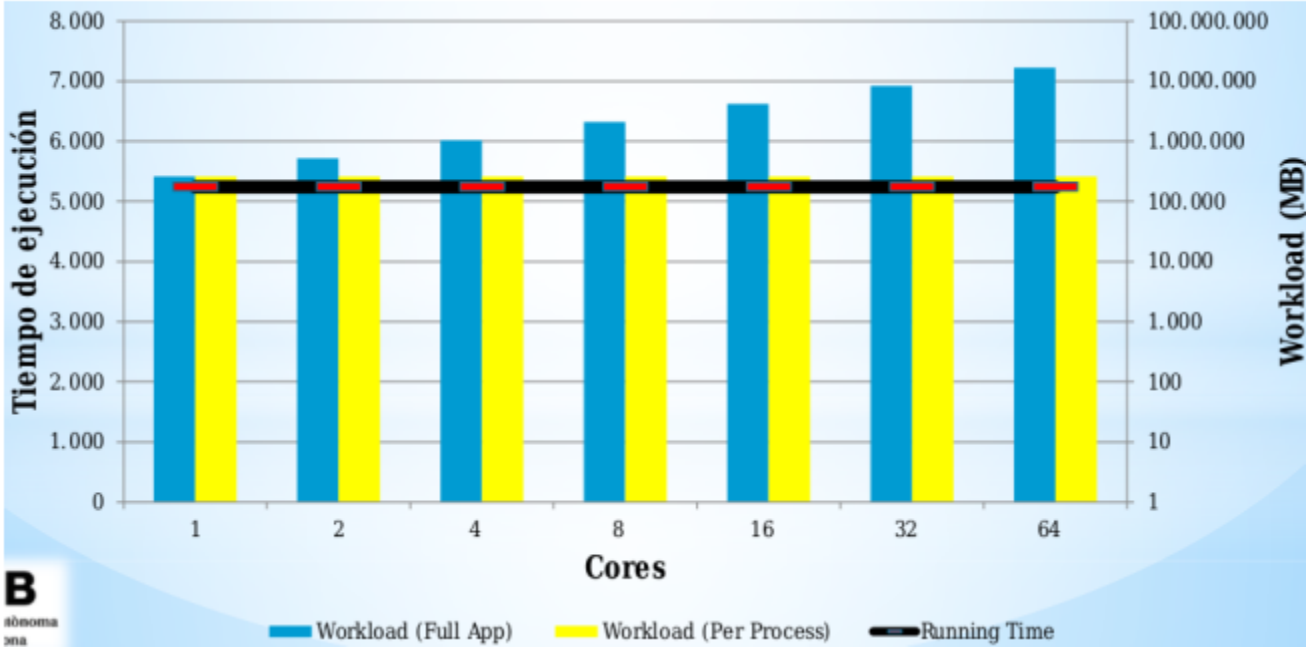

Métricas – Ley de Gustafson

- El incremento en el Speedup por un tamaño mayor de problema no es percibido por la Ley de Amdahl

$$\lim_{p \to \infty} \left(\frac{1}{f \times + \frac{(1-f)}{p}} \right) = \frac{1}{f}$$

Métricas – Ley de Gustafson

- El incremento en el Speedup por un tamaño mayor de problema no es percibido por la Ley de Amdahl
- En la década del 80, Gustafson observó en la práctica que:
  - Un multiprocesador más grande usualmente permite resolver un problema de mayor tamaño en un tiempo de ejecución determinado (*escalabilidad*) → el tamaño de problema seleccionado depende frecuentemente del número de unidades de procesamiento disponibles
  - Al incrementar el tamaño del problema y el número de unidades de procesamiento para mantener el tiempo de ejecución constante, la fracción secuencial de los programas se mantiene fija o no crece en forma proporcional al tamaño de la entrada.
- Por lo tanto, asumir que el tamaño de problema es fijo resulta tan válido como que el tiempo de ejecución paralela lo es

Métricas – Ley de Gustafson

- Basándose en sus observaciones, Gustafson re-escribió la ecuación para estimar el máximo speedup alcanzable (conocido como *Speedup escalado*).
- Dada una fracción *f'*, $0 \leq f' \leq 1$, de un programa paralelo que debe ser ejecutada secuencialmente pero que no crece en forma proporcional al tamaño de problema, el Speedup escalado se calcula como:

$$S^S{}_p(n) = \frac{T_s(n)}{T_p(n)} = \frac{f' \times T_p(n) + (1 - f') \times T_p(n) \times p}{T_p(n)} = p + (1 - p) \times f'$$

- Esta versión requiere 2 suposiciones: (1) $T_p(n)$ se mantiene constante y (2) $f' \times T_p(n)$ no escala en forma proporcional al aumento de *n* y *p*
- Según Gustafson: con 5% de ejecución secuencial ($f' = 0.05$) y 20 procesadores, el speedup alcanzable sería $20 + (1 - 20) \times 0{,}05 = \mathbf{19.05}$ en lugar de $\frac{1}{0.05 \times + \frac{(1-0.05)}{20}} = \mathbf{10.26}$ que se obtendría con la ecuación de Amdahl.

Métricas – Escalabilidad

- Análisis según Speedup

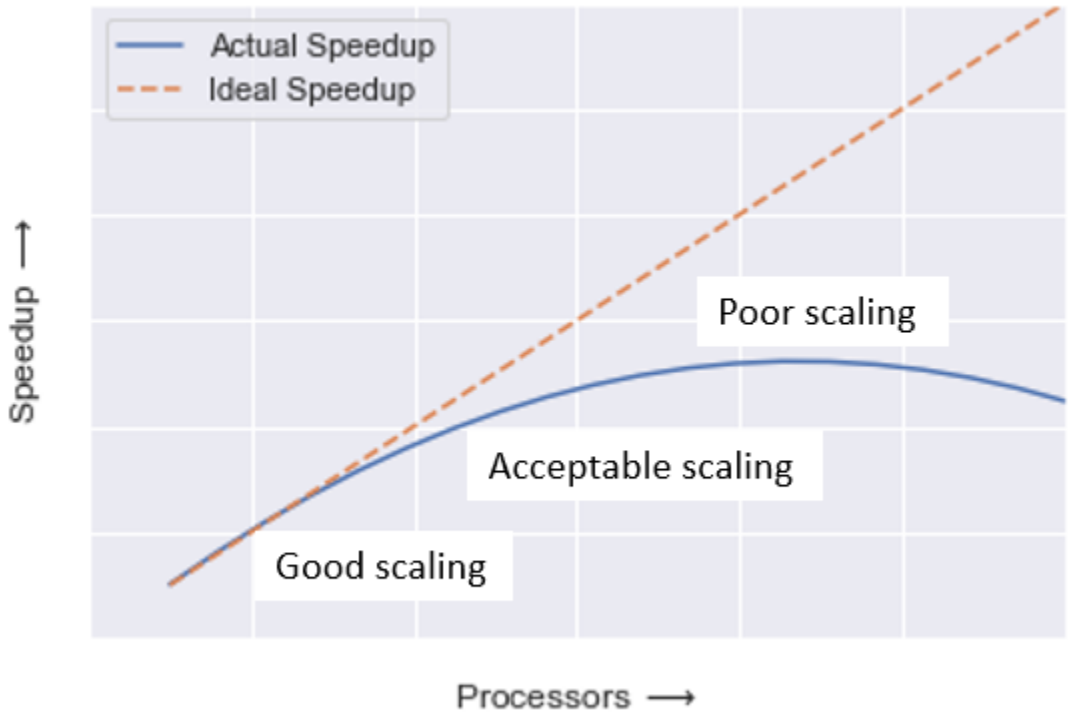

Métricas – Escalabilidad

- Análisis según Eficiencia

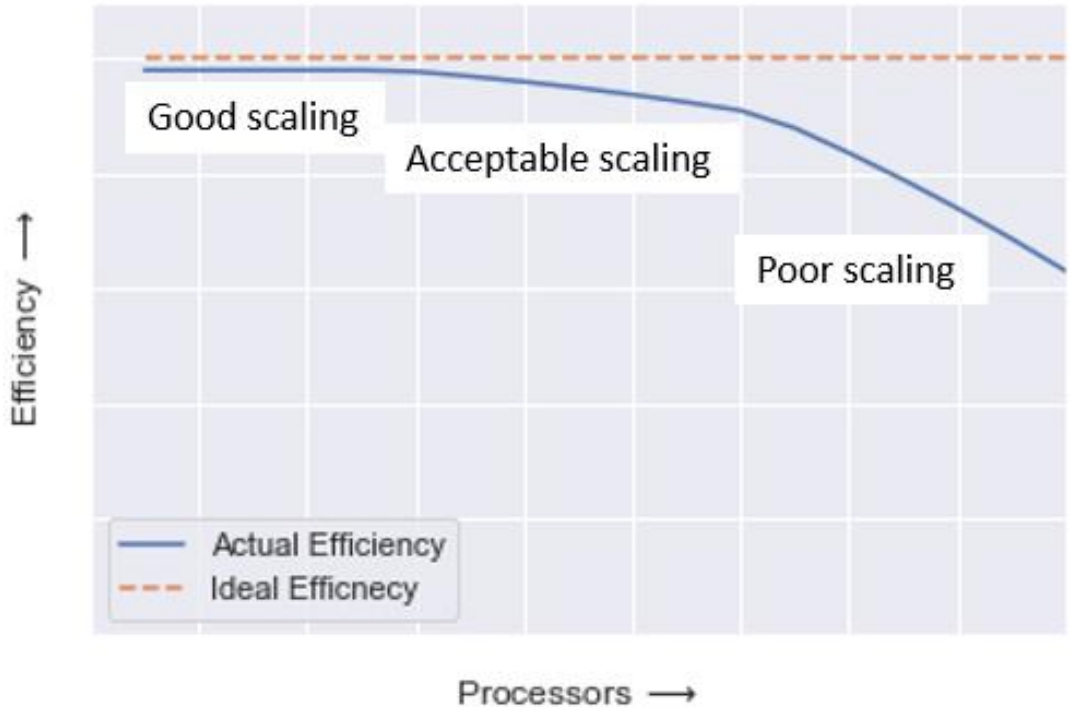

Métricas – Escalabilidad: resumen y comentarios finales

- Escalabilidad fuerte (Amdhal)
  - El tamaño del problema se mantiene fijo a medida que se incrementa la cantidad de procesadores.
  - El objetivo es resolver el mismo problema de forma más rápida
  - El *escalado perfecto* se logra cuando el problema se resuelve en 1/P unidades de tiempo (comparado al secuencial)
- Escalabilidad débil (Gustafson)
  - El tamaño del problema *por procesador* se mantiene fijo a medida que se incrementa la cantidad de procesadores → El tamaño total del problema es proporcional al número de procesadores usados.
  - El objetivo es resolver un problema más grande en la misma cantidad de tiempo
  - El *escalado perfecto* se logra cuando se resuelve un problema P veces más grande en la misma cantidad de tiempo que el secuencial.

Métricas – Escalabilidad: resumen y comentarios finales

- La capacidad de un programa paralelo de escalar su rendimiento depende de un conjunto de factores interrelacionados → Agregar más procesadores no suele ser una solución directa.
- Los algoritmos pueden tener límites inherentes para su escalabilidad.
  - Incluso agregar más recursos puede perjudicar el rendimiento en un determinado punto.
  - Es una situación usual en varias aplicaciones paralelas.
- Los recursos de hardware desempeñan un factor fundamental en la escalabilidad. Ejemplos:
  - Ancho de banda del bus de memoria en un multiprocesador
  - Ancho de banda de red
  - Memoria prinicipal disponible en una máquina (o un conjunto de ellas)
  - Frecuencia del reloj del procesador

Métricas – Desbalance de carga

- En arquitecturas heterogéneas o soluciones paralelas que contemplan problemas irregulares, resulta útil poder medir el ***Desbalance de carga***:

$$D = \frac{max_{i=0..p-1}\left(T_{pi}(n)\right) - min_{i=0..p-1}(T_{pi}(n))}{prom_{i=0..p-1}(T_{pi}(n))}$$

- Si todas las unidades de procesamiento toman el mismo tiempo, entonces $D = 0 \rightarrow$ Poco usual
- En general, se debe intentar que D esté lo más cerca posible de 0

Métricas – FLOPS

- Denota la *cantidad de operaciones de punto flotante por segundo* que un sistema computacional puede alcanzar
- Se usa para calcular:
  - El pico de rendimiento teórico de un sistema → Se tiene en cuenta características de hardware como cantidad de cores, frecuencia de reloj y capacidad vectorial
  - El rendimiento real de un sistema para una aplicación dada → Se calcula la cantidad de operaciones en punto flotante que realizó en un determinado plazo de tiempo

Ventajas	Desventajas
• Estándar • Simple • Permite evaluar escalabilidad	• No es general • No considera eficiencia • No refleja tiempo de respuesta

Métricas – FLOPS

- FLOPS “teóricos”

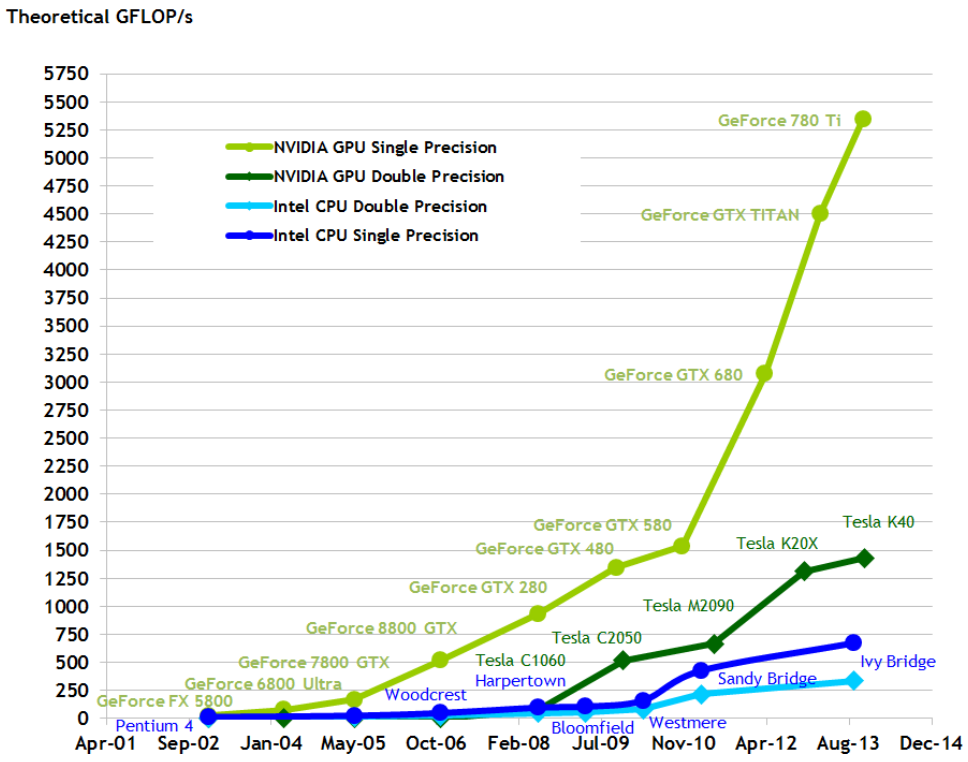

Métricas – FLOPS

- FLOPS “reales”

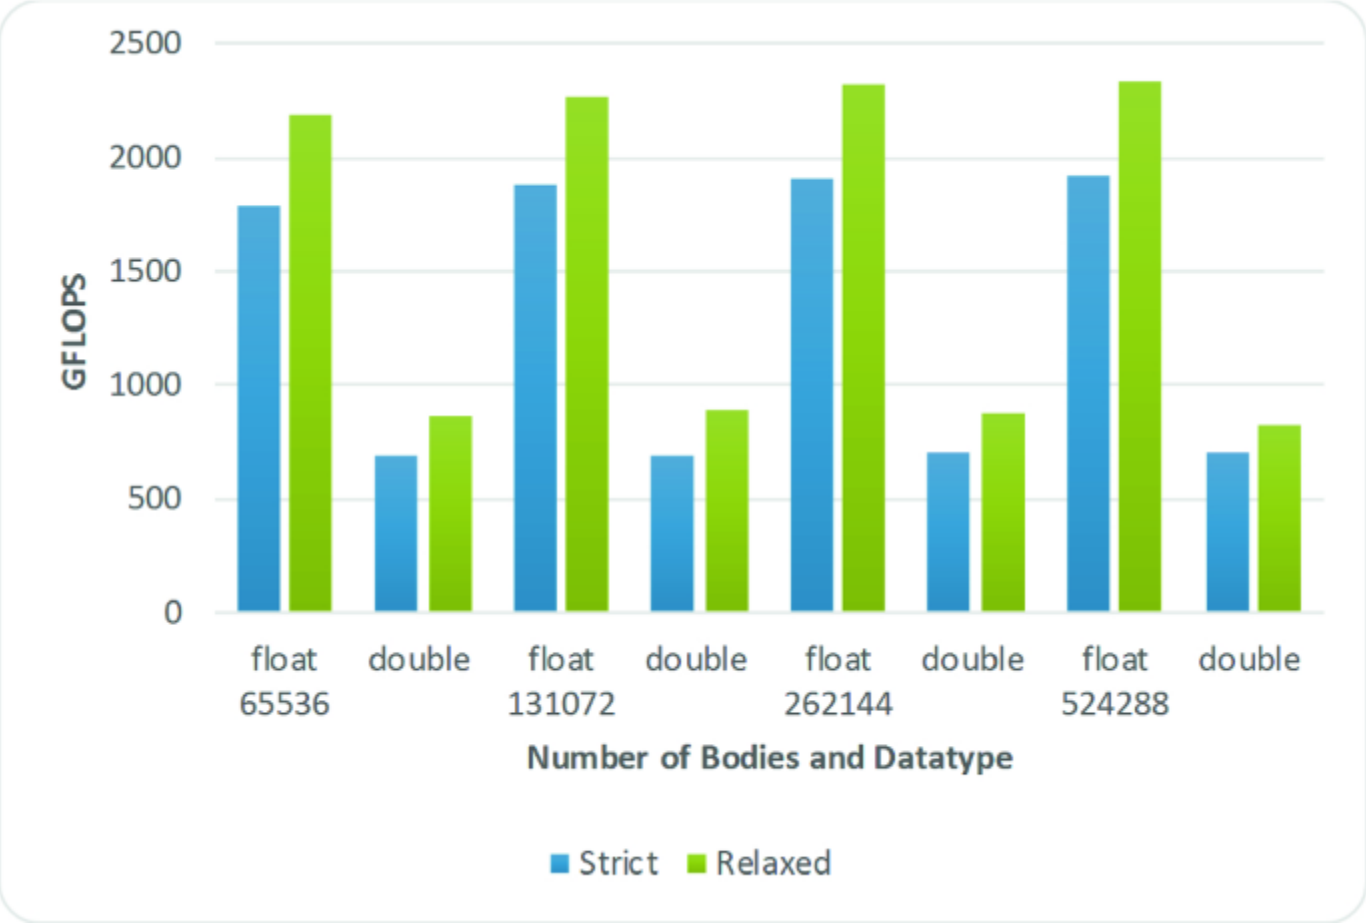

Métricas – Algunos casos para analizar

- Análisis basado en tiempo de ejecución

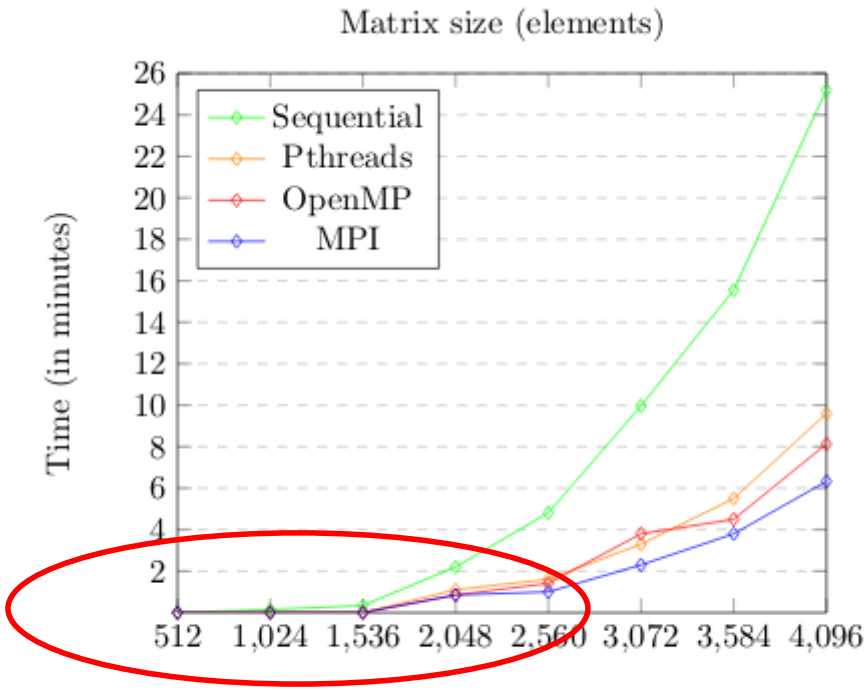

Figure 1: Dependence of matrix size on norm calculation.

Cantidad de cores fija

Problema de escala

Métricas – Algunos casos para analizar

- Análisis de speedup

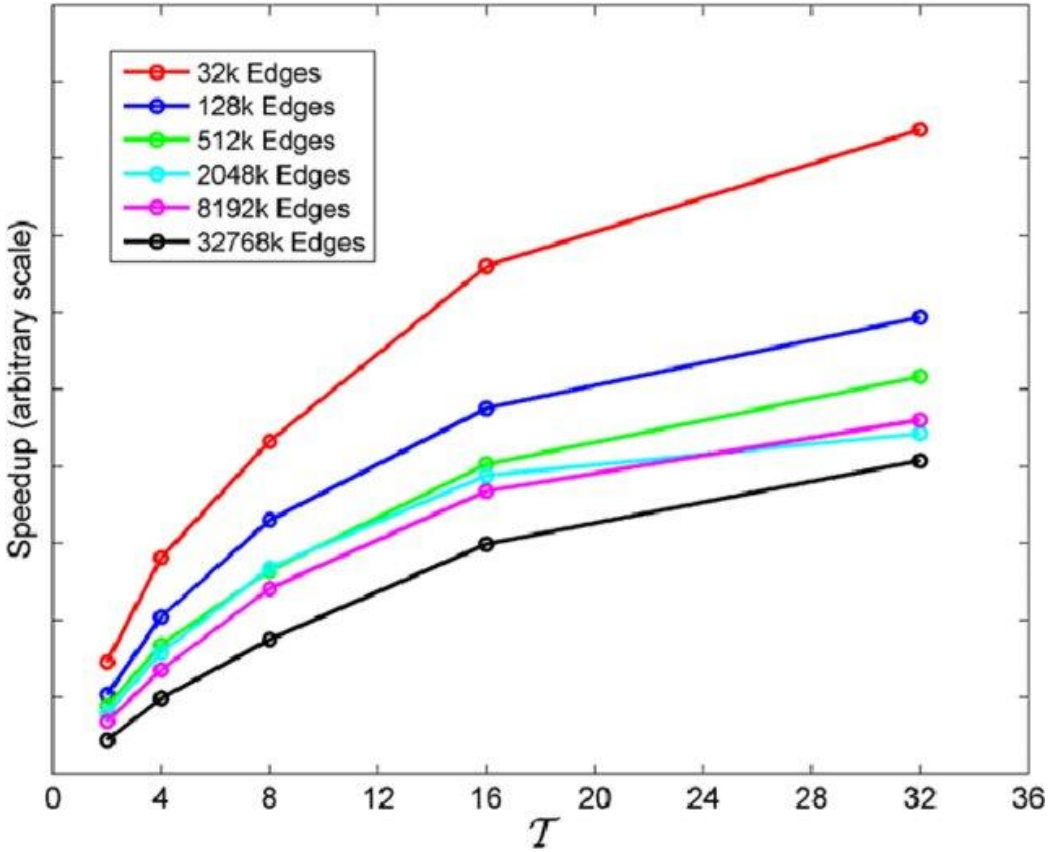

Foco en tamaño

No tan habitual

Métricas – Algunos casos para analizar

- Comparación entre 2 versiones paralelas

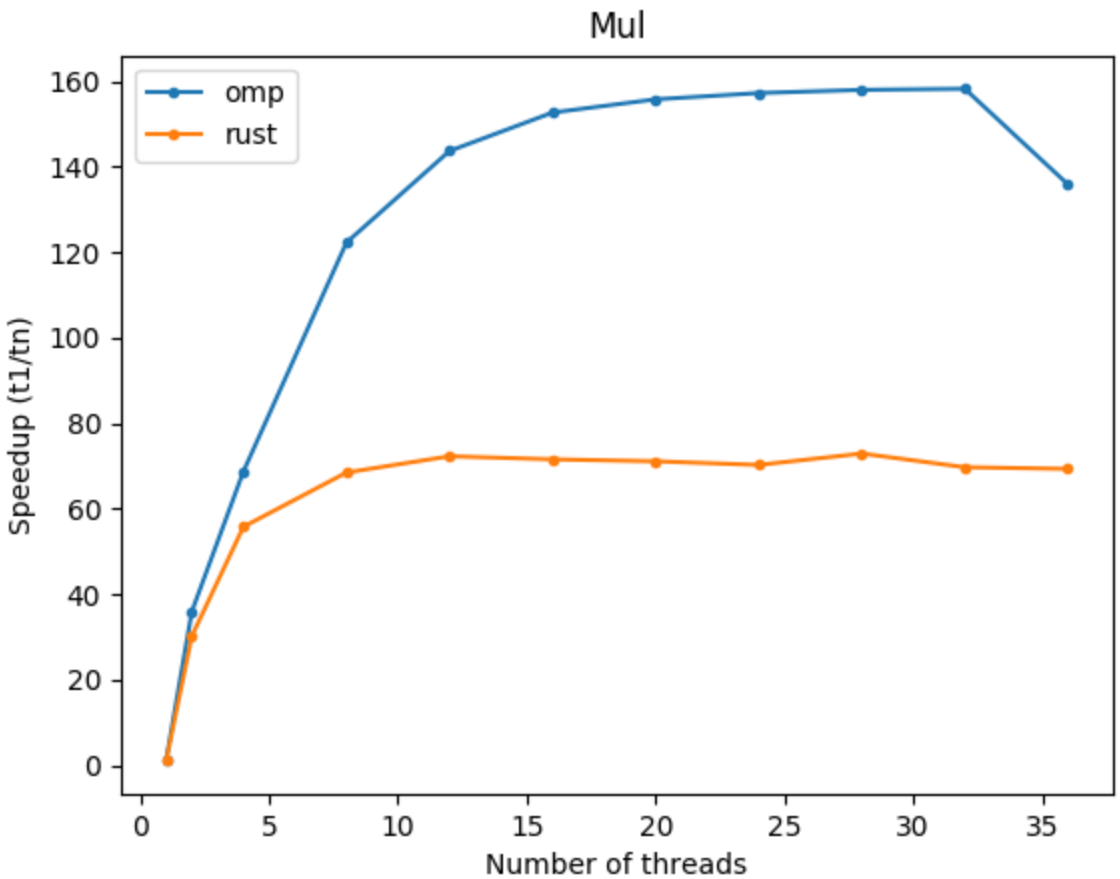

Tamaño de problema fijo

Recomendaciones a la hora de optimizar

- Tener en cuenta el principio de Pareto aplicado a la ingeniería de software:

  90% del tiempo de ejecución se dedica a ejecutar 10% del código

- También conocida como “regla 90/10”.

¿Qué será más beneficioso? ¿Acelerar 5x la parte B? ¿o 2x la parte A?

Recomendaciones a la hora de optimizar

- Tener en cuenta el principio de Pareto aplicado a la ingeniería de software:

  90% del tiempo de ejecución se dedica a ejecutar 10% del código

- En este contexto, se conoce como “regla 90/10”.

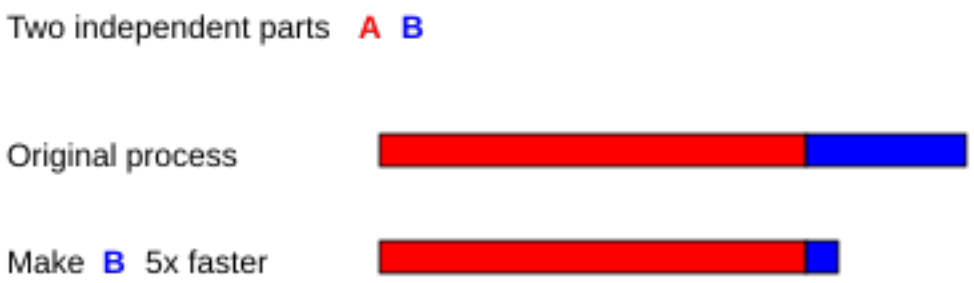

Recomendaciones a la hora de optimizar

- Tener en cuenta el principio de Pareto aplicado a la ingeniería de software:

  90% del tiempo de ejecución se dedica a ejecutar 10% del código

- En este contexto, se conoce como “regla 90/10”.

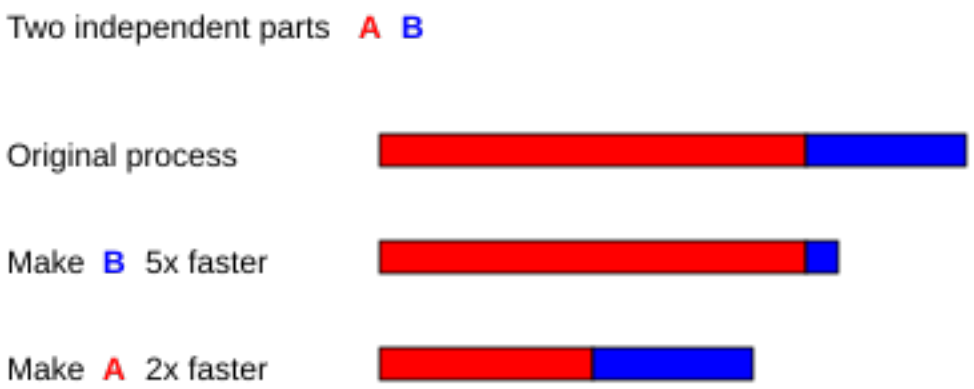

Recomendaciones a la hora de optimizar

- En programas pequeños, uno puede identificar fácilmente donde está sección de código que más demanda computacional tiene (a esto se lo conoce como *hotspot*).
  - Observando y analizando el código (habitualmente los bucles)
  - Instrumentando el código “a mano” (tomar tiempos de diferentes secciones)
- En programas de complejidad mediana o alta, se realiza un proceso llamado *profiling* (o perfilado).
- Mediante herramientas de software, se analiza y mide el rendimiento de una aplicación o programa → el objetivo principal es identificar los puntos críticos de la aplicación que consumen la mayor cantidad de tiempo de ejecución o recursos del sistema.
- Hay muchos profilers diferentes, según el lenguaje, el aspecto a mejorar, la modalidad de uso, entre otros
- C (gprof, Valgrind, VTune), Python (cProfile, profile), Julia (profile)

Recomendaciones para medir tiempos de ejecución

- Usualmente interesa analizar la mejora lograda en determinada parte del programa → En la práctica, el tiempo de ejecución no siempre se considera desde el que programa empieza hasta que el mismo termina
- Por ejemplo, si consideramos un problema de ordenación por burbuja, mediremos la parte que ordena el vector, pudiendo descartar:
  - Reserva de memoria
  - Lectura de datos de entrada
  - Impresión de datos de salida
  - Liberación de memoria

Recomendaciones para medir tiempos de ejecución

- Aunque la solución paralela involucre *p* tareas, $T_p(n)$ debe ser un único valor que contemple el tiempo que transcurre desde que la primera tarea comenzó a ejecutar hasta que la última haya completado su trabajo → Tener en cuenta que este tiempo puede hacer referencia a una determinada parte del programa
- En ocasiones, no todas las tareas comienzan y terminan al mismo tiempo → Para asegurarnos una medición correcta, puede ser útil emplear *barreras*
- La precisión en la medición puede ser un tema importante → No es lo mismo medir un programa que dure unos pocos segundos a otro que dure horas…

Recomendaciones para medir tiempos de ejecución

- Otro factor a tener en cuenta es la variabilidad en las mediciones
  - Se recomienda repetir las pruebas un determinado número de veces y calcular el promedio o la mediana → ¿Cuántas veces repetirlo?
  - En ocasiones, también puede ser de interés reportar el tiempo mínimo y el máximo

Bibliografía usada para esta clase

- Capítulo 5, An Introduction to Parallel Computing. Design and Analysis of Algorithms (2da Edition). Grama A., Gupta A., Karypis G. & Kumar V. (2003) Inglaterra: Pearson Addison Wesley.
- Capítulo 4, Parallel Programming for Multicore and Cluster Systems. Rauber, T. & Rünger, G. (2010). EEUU: Springer-Verlag Berlin Heidelberg.
- Capítulo 2, An Introduction to Parallel Programming. Pacheco, P. (2011) EEUU: Elsevier.
- Capítulo 1, Parallel Programming. Wilkinson, B. & Allen, M. (2005) EEUU, Pearson